Qwen2.5-Omni 音视频伪造检测阶段性结果分析

一、当前两阶段做法

我们当前复现的是两步训练：

阶段	做法	当前冻结/训练范围	重点说明
Stage 1	LoRA 指令微调	主要通过 LoRA 适配模型，让模型学会按 `Real/Fake` 输出	用于快速对齐二分类任务
Stage 2	在 Stage 1 基础上继续 full tuning	**当前冻结 LLM 主干，只训练视觉编码器和 aligner**	**论文只明确说打开音视频编码器，没有完全说清 LLM 主干是否也训练；这里可能是复现差异来源**

两个数据集的特殊设置：

数据集	当前设置	原因
FakeAVCeleb	使用正常视频输入，没有额外 FPS/帧数限制	视频整体较短，当前主要问题不是算力，而是结果明显异常
MAVOS-DD	`FPS=2.0`，`FPS_MAX_FRAMES=64`，并限制视频像素	**MAVOS-DD 视频普遍更长，是当前 2x4090 下评估和训练耗时的主要瓶颈**

二、数据集划分与分布

FakeAVCeleb

当前 FakeAVCeleb 使用 70% / 30% 切分，并把 `F-F`、`F-R`、`R-F`、`R-R` 都纳入二分类。只要音频或视频有伪造，就标为 `Fake`。

划分	总数	Fake	Real	Fake 占比	Real 占比
Train	15080	14730	350	97.68%	2.32%
Eval	6464	6314	150	97.68%	2.32%

划分	F-F	F-R	R-F	R-R
Train	7584	6796	350	350
Eval	3251	2913	150	150

这个划分极度偏 Fake，预测全 Fake 的 accuracy baseline 就是 97.68%。因此当前 FakeAVCeleb 不能只看 accuracy，也需要看 Fake recall、Real recall 和 balanced accuracy。

MAVOS-DD

MAVOS-DD 按官方思路包含 in-domain、open-language、open-model、open-full 等 split。当前训练集整体比 FakeAVCeleb 平衡，但不同测试 split 的真假比例差异很大。

划分	总数	Fake	Real	说明
Train	21370	11073	10297	基本平衡
Validation	3895	2180	1715	基本可用
In-domain	12408	7223	5185	已完成评估
Open-language	13330	5332	7998	已完成评估
Open-model	31551	21189	10362	评估尚未完整汇总
Open-full	4484	4484	0	**统计异常，需要复核标签构造**

MAVOS-DD 长视频是当前算力瓶颈。即使限制到 2 FPS 和最多 64 帧，open-model / open-full 的完整评估仍然很慢。

三、已有结果

FakeAVCeleb

方法	Accuracy	AUC	AP/mAP	Fake recall	Real recall	Balanced Acc
Base / without SFT	17.65%	0.6290	0.9835	15.93%	90.00%	52.97%
Stage 1 LoRA	30.21%	0.6334	0.9850	29.00%	81.33%	55.17%
Stage 2 only	18.84%	0.6245	0.9833	17.18%	88.67%	52.93%
Stage 1 -> Stage 2	30.93%	0.5666	0.9831	29.71%	82.00%	55.86%

FakeAVCeleb 的核心问题很明确：验证集 97.68% 是 Fake，但模型大量预测 Real，导致 accuracy 很低。Stage 1 和 Stage 1 -> Stage 2 有提升，但仍没有解决 Fake 漏检。

MAVOS-DD

Split	状态	Accuracy	AUC	AP/mAP	Fake recall	Real recall	Balanced Acc
In-domain	完整	80.76%	0.9503	0.9662	68.07%	98.33%	83.20%
Open-language	完整	83.78%	0.9388	0.9231	62.84%	97.74%	80.29%
Open-model	未完整	65.59%	-	-	47.92%	97.24%	72.58%

MAVOS-DD 结果比 FakeAVCeleb 正常，但同样偏向预测 Real：Real recall 很高，Fake recall 偏低。实际伪造检测中，这意味着漏检 Fake 的风险仍然明显。

四、与论文结果对比

为了直接看差距，下面把论文 AV-LMMDetect 结果和我们当前结果放在同一张表里。未完整跑完的结果单独标注，不作为最终结论。

数据集 / Split	论文 Acc	论文 AUC	论文 mAP	我们当前 Acc	我们当前 AUC	我们当前 AP/mAP	当前状态
FakeAVCeleb	98.02%	99.2	-	30.93%	0.5666	0.9831	Stage 1 -> Stage 2 已完成，但结果异常
MAVOS-DD In-domain	92.92%	0.97	0.97	80.76%	0.9503	0.9662	已完成
MAVOS-DD Open-language	85.58%	0.90	0.88	83.78%	0.9388	0.9231	已完成，最接近论文
MAVOS-DD Open-model	87.91%	0.94	0.98	65.59%	-	-	**未完整跑完，仅 worker partial 结果**
MAVOS-DD Open-full	85.09%	0.92	0.96	-	-	-	**未跑完；且当前标签统计异常，需要先复核**

从表里可以看到：我们当前最接近论文的是 MAVOS-DD open-language，accuracy 83.78%，和论文 85.58% 差距不大；in-domain 的 AUC/mAP 接近论文，但 accuracy 明显低。**FakeAVCeleb 与论文差距最大，当前不是轻微复现误差，而是判别方向存在明显问题。**

五、当前重点问题判断

我们的主要猜测如下：

1. **FakeAVCeleb 数据极度不平衡，且当前模型反而偏向预测 Real，这是最优先的问题。** 这可能来自训练不足、prompt/token 校准、类别构造，或当前 Real/Fake 判决阈值不适合该分布。
2. **Stage 2 的冻结范围可能和论文不完全一致。** 我们当前冻结 LLM，只训练视觉编码器和 aligner；如果论文实际也训练了语言侧或更多跨模态参数，就会造成明显差异。
3. **MAVOS-DD 的主要问题是长视频导致评估成本过高，open-model / open-full 还没有形成完整可靠结果。** 当前 open-model 只能作为 partial 参考，不能作为最终指标。
4. **MAVOS-DD open-full 的标签统计异常必须先复核。** 统计中出现 Fake=4484、Real=0，但生成方法里又包含 real，这说明数据构造或统计逻辑可能有问题。
5. **当前结果与论文差距不能只归因于 epoch 少。** epoch 少确实会影响收敛，但 FakeAVCeleb 的大量 Fake 判 Real 更像是数据分布、判别阈值、训练策略或第二阶段解冻范围共同导致的问题。